# Bohdan's legacy
# Logistická regresia pomocou gradientnej metódy (Predikcia nevyžiadanej pošty)

Yarislav Riabikov(0.2), Mykyta Miendiukov(0.2),
Vitalii Kuzmenko(0.2), Nazar Shevchuk(0.2), Yurii Palchinskiy(0.2)

# 1. Analytická časť

## (a) Účelová funkcia

$$\min \left\{ J(x) = -\sum_{i=1}^{m} v^i \ln\left(g(x^T u^i)\right) + (1-v^i)\ln\left(1-g(x^T u^i)\right) \;\middle|\; x \in \mathbb{R}^5 \right\}$$

Dosadíme sigmoid:

$$g(z) = \frac{1}{1+e^{-z}}$$

$$\ln\left(g(x^T u^i)\right) = \ln\left(\frac{1}{1+e^{-x^T u^i}}\right) = -\ln\left(1+e^{-x^T u^i}\right)$$

$$\ln\left(1-g(x^T u^i)\right) = \ln\left(\frac{e^{-x^T u^i}}{1+e^{-x^T u^i}}\right) = \ln\left(e^{-x^T u^i}\right) - \ln\left(1+e^{-x^T u^i}\right)$$

Dosadíme do sumy:

$$v^i\left(-\ln(1+e^{-x^T u^i})\right) + (1-v^i)\left(-x^T u^i - \ln(1+e^{-x^T u^i})\right)$$

Uprava:

$$(1-v^i)x^T u^i + \ln(1+e^{-x^T u^i})$$

Výsledná funkcia:

$$\min \left\{ J(x) = \sum_{i=1}^{m} \left[(1-v^i)x^T u^i + \ln(1+e^{-x^T u^i})\right] \;\middle|\; x \in \mathbb{R}^5 \right\}$$

## (b) Gradient

$$\frac{\partial J}{\partial x_j} = \sum_{i=1}^{m}(x^T u^i - v^i x^T u^i + \ln(1+e^{-x^T u^i}))' = \sum_{i=1}^{m}(u_j^i - v^i u_j^i + \frac{e^{-x^T u^i}}{1+e^{-x^T u^i}}(-u_j^i))$$

$$= (1 - v^i - \frac{e^{-x^T u^i}}{1+e^{-x^T u^i}})u^i = (\frac{1+e^{-x^T u^i} - e^{-x^T u^i}}{1+e^{-x^T u^i}} - v^i)u^i = (\frac{1}{1+e^{-x^T u^i}} - v^i)u^i$$

# 2. Výsledky experimentov – gradientné metódy

## Referenčné riešenie

Ako referenčné riešenie bolo použité minimum získané metódou BFGS:

$$x_{\text{opt}} \approx (-1.47377220,\ 3.07173693,\ 10.1906655,\ 17.7027043,\ 0.00484403)$$

Štartovací bod:

$$x_0 = (-1.47, 0, 0, 0, 0)^T$$

Kritérium zastavenia:

$$\|\nabla J(x^k)\|^2 < 10^{-3}$$

## (c) Gradientná metóda s konštantným krokom

Metóda bola testovaná pre rôzne hodnoty konštantného kroku $c$

$c = 3 \times 10^{-7}$

- **Výsledok:** $x_c \approx (-0.99398804,\ 3.0594658,\ 4.61121505,\ 5.98086102,\ 0.007168)$
- **Chyba:** $\|x_c - x_{\text{opt}}\|_2 \approx 12.990851628224819$
- **Počet iterácií:** 5 000 000 (limit)
- **Čas:** 137.47 s

Krok je príliš malý, metóda konverguje extrémne pomaly a nedosiahne riešenie ani po maximálnom počte iterácií.

$c = 3 \times 10^{-5}$

- **Výsledok:** $x_c \approx (-1.47360963,\ 3.07175527,\ 10.1989855,\ 17.6905539,\ 0.00484668)$
- **Chyba:** $\|x_c - x_{\text{opt}}\|_2 \approx 0.01472689$
- **Počet iterácií:** 2 736 859
- **Čas:** 71.24 s

Táto hodnota kroku vedie k stabilnej konvergencii, avšak za cenu veľkého počtu iterácií.

Metóda je stabilná pre c=$3 \times 10^{-5}$, ale pomalá. Počet iterácií je veľmi vysoký, čo je dôsledok pevného kroku bez adaptácie.

$c = 3 \times 10^{-3}$

- **Výsledok:** $x_c \approx (-7.89528871,\ 8.27025728,\ 22.63379642,\ 48.20722059,\ 5.6435618)$
- **Chyba:** $\|x_c - x_{\text{opt}}\|_2 \approx 34.42982206475787$
- **Počet iterácií:** 5 000 000 (limit)
- **Čas:** 134.27 s

Krok je príliš veľký, metóda je nestabilná a cieľová funkcia nerastie monotónne, čo vedie k divergencii.

Voľba konštantného kroku má zásadný vplyv na konvergenciu:

- príliš malý krok spôsobuje veľmi pomalú konvergenciu,
- vhodne zvolený krok vedie k stabilnému riešeniu,
- príliš veľký krok spôsobuje divergenciu.

## (d) Gradientná metóda s približne optimálnou dĺžkou kroku

- **Výsledok:** $x_d \approx (-1.47361102,\ 3.07175538,\ 10.1989558,\ 17.6906325,\ 0.00484666)$
- **Chyba:** $\|x_d - x_{\text{opt}}\|_2 \approx 0.01464526$
- **Počet iterácií:** 631 781
- **Čas:** 376.17 s
- **Získané lambdy:** $\lambda_{\min} \approx 5.58 \times 10^{-6}, \quad \lambda_{\max} \approx 6.97 \times 10^{-6}$

Backtracking výrazne zrýchľuje konvergenciu oproti konštantnému kroku a stabilizuje výber dĺžky kroku.

## (e) Gradientná metóda s optimálnou dĺžkou kroku

Optimalizácia dĺžky kroku bola realizovaná pomocou metódy zlatého rezu.

**Interval** $[0.1\lambda_{\min}, 10\lambda_{\max}]$

- **Výsledok:** $x_e \approx (-1.47363523,\ 3.07175410,\ 10.1979473,\ 17.6922987,\ 0.00484631)$
- **Chyba:** $\|x_e - x_{\text{opt}}\|_2 \approx 0.012701188$
- **Počet iterácií:** 2 547 196
- **Čas:** 471.59 s

**Interval** $[\lambda_{\min}, \lambda_{\max}]$

- **Výsledok:** $x'_e \approx (-1.46249642,\ 3.06969473,\ 10.2376301,\ 17.1934336,\ 0.00494678893)$
- **Chyba:** $\|x'_e - x_{\text{opt}}\|_2 \approx 0.5115600100544843$
- **Počet iterácií:** 5 000 000 (limit)
- **Čas:** 305.05 s

Z porovnania metód vyplýva:

- Konštantný krok je najpomalší a vyžaduje najviac iterácií.
- Backtracking výrazne zlepšuje konvergenciu a stabilitu výberu kroku.
- Metóda zlatého rezu je citlivá na voľbu intervalu:
  - širší interval vedie k lepšej presnosti a rýchlejšej konvergencii,
  - úzky interval môže spôsobiť stagnáciu a výrazne horšie výsledky.

Experimenty potvrdzujú, že efektivita gradientných metód silne závisí od vhodnej voľby dĺžky kroku a škálovania problému.

## (f) Porovnanie konvergencie gradientných metód

Znázorníme, ako sa mení hodnota $|J(x_k) - J|$ v závislosti od počtu iterácií pre jednotlivé metódy. Na osi $y$ použijeme logaritmickú mierku, aby boly lepšie viditeľné malé hodnoty.

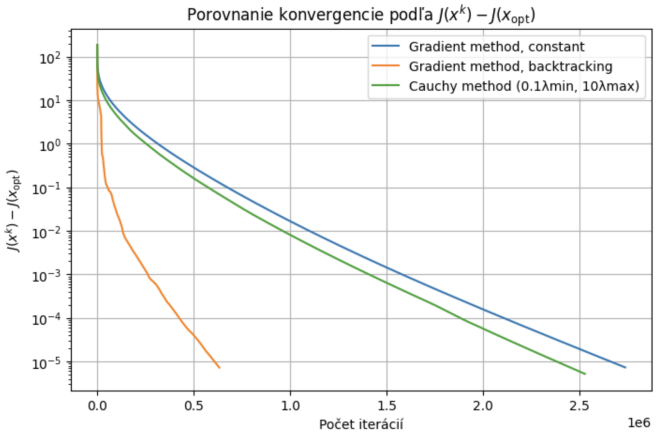


• Metóda backtrackingu potrebuje najmenší počet iterácií na konvergenciu. Jednotlivé iterácie tejto metódy nás najviac približujú k optimálnej hodnote $J^*$. Na druhej strane však podľa výsledkov úlohy **e)** trvá táto metóda najdlhšie.

• Gradientná metóda s konštantným krokom a Cauchyho metóda majú podobný priebeh konvergencie. Z výsledkov časti **e)** vieme, že gradientná metóda s konštantným krokom je výrazne rýchlejšia, z toho vyplýva, že rýchlosť konvergencie nezávisí len od počtu iterácií.

## (g) Kvalita klasifikácie modelu

Ako najlepšiu metódu sme zvolili gradientnú metódu s konštantným krokom $c = 3 \times 10^{-5}$.
Získaný vektor parametrov $x = (-1.47360963,\ 3.07175527,\ 10.1989855,\ 17.6905539,\ 0.00484668)$.

**Klasifikáciu počítame nasledovne:**

Nech $x$ sú parametre modelu a $u$ je vstup modelu. Teda pravdepodobnosť, že daný vstup $u$ je spam:

$$P(v = 1 \mid u_1, \ldots, u_4) = \frac{1}{e^{-x^T u} + 1}.$$

Ohodnotíme parametre modelu na testovacích dátach. Ako metriku hodnotenia používame **accuracy**, ktorá je definovaná takto:

$$\textbf{accuracy} = \frac{\text{počet správne klasifikovaných}}{\text{celkový počet}}.$$

Získané výsledky: **accuracy** $\approx 88{,}68\,\%$.
Zo 53 testovacích vstupov bolo 47 klasifikovaných správne, čo je dobrý výsledok. Či možeme dosiahnuť accuracy vyššiu ako 88 %? Musíme si uvedomiť, že dáta nie sú vždy dokonale lineárne separovateľné, preto v praxi očakávame chybu.

**Pre zaujímavosť vyhodnotíme výsledky najhoršej metódy.**

Najhoršia metóda je gradientná metóda s konštantným krokom $c = 10^{-3}$.
$x \approx (-7.89528871,\ 8.27025728,\ 22.63379642,\ 48.20722059,\ 5.6435618)$, pričom $\|x - x_{\text{opt}}\| \approx 34$.

**accuracy** $\approx 64.15\%$.
Vidíme, že model funguje o niečo lepšie ako náhodná klasifikácia, čo potvrdzuje, že parametre vzdialené od minima sú nevhodné.

## (h) Hessova matica, konvexnosť a Lipschitzova konštanta

**Hessova matica $\nabla^2 J(x)$**

Vyjdeme z tvaru gradientu z časti (b):

$$\frac{\partial J}{\partial x_j} = \sum_{i=1}^{m} u_j^i \left( g(x^T u^i) - v^i \right),$$

Druhá parciálna derivácia:

$$\frac{\partial^2 J}{\partial x_j \partial x_k} = \sum_{i=1}^{m} u_j^i \cdot \frac{\partial}{\partial x_k} g(x^T u^i) = \sum_{i=1}^{m} u_j^i \cdot g(x^T u^i)\big(1 - g(x^T u^i)\big) \cdot u_k^i.$$

V maticovom zápise:

$$\nabla^2 J(x) = \sum_{i=1}^{m} g^i (1 - g^i)\, u^i (u^i)^T = U^T \operatorname{diag}\big(g \odot (1 - g)\big)\, U$$

**Konvexnosť $J(x)$**

Pre ľubovoľný vektor $z \in \mathbb{R}^5$ platí:

$$z^T \nabla^2 J(x)\, z = \sum_{i=1}^{m} \underbrace{g^i (1 - g^i)}_{\geq 0} \underbrace{(z^T u^i)^2}_{\geq 0} \geq 0.$$

Keďže $g^i \in (0, 1)$, je $g^i(1 - g^i) \geq 0$ pre každé $i$. Hessova matica je teda pozitívne semidefinitná pre každé $x \in \mathbb{R}^5$, čo dokazuje konvexnosť $J(x)$.

**Dôkaz nerovnosti (4)**

Funkcia $g^i(1-g^i)$ nadobúda na intervale $[0,1]$ maximum v bode $g^i = \frac{1}{2}$ ; $g^i(1-g^i) \leq \frac{1}{4}$ pre všetky $i$.

Z toho plynie nerovnosť:

$$\nabla^2 J(x) = \sum_{i=1}^{m} g^i(1-g^i)\, u^i (u^i)^T \preceq \frac{1}{4} \sum_{i=1}^{m} u^i (u^i)^T.$$

Pre PSD matice $A \preceq B$ platí $\lambda_{\max}(A) \leq \lambda_{\max}(B)$, a keďže spektrálna norma PSD matice sa rovná jej najväčšiemu vlastnému číslu, dostávame:

$$\|\nabla^2 J(x)\|_2 \leq \frac{1}{4} \left\| \sum_{i=1}^{m} u^i (u^i)^T \right\|_2 = \frac{1}{4} \|U^T U\|_2.$$

**Lipschitzovsky spojitý gradient**

**Tvrdenie:** Ak $\|\nabla^2 f(x)\|_2 \leq L$ pre všetky $x$, potom $\nabla f$ je $L$-Lipschitzovský, t. j. $\|\nabla f(x) - \nabla f(y)\| \leq L\|x-y\|$. Dôkaz tohto tvrdenia možno nájsť v literatúre: Y. Nesterov, *Introductory Lectures on Convex Optimization*, Kluwer Academic Publishers, 2004, Kapitola 1.2.2.

**Lipschitzova konštanta a vhodný interval pre krok $c$**

Kombináciou nerovnosti (4) s predchádzajúcim tvrdením dostávame Lipschitzovu konštantu gradientu $\nabla J$:

$$L = \frac{1}{4}\|U^T U\|_2 = \frac{724\,440{,}52}{4} \approx 181\,110{,}13.$$

Pre gradientnú metódu s konštantným krokom je postačujúca podmienka zaručenej konvergencie:

$$0 < c < \frac{2}{L} \approx \frac{2}{181\,110{,}13} \approx 1{,}1 \times 10^{-5}.$$

Prehlasujeme, že sme tento projekt vypracovali samostatne, s využitím iba povolených zdrojov. Všetky použité zdroje (vrátane literatúry, online materiálov a nástrojov) sú v reporte riadne uvedené. Nepoužili sme nepovolené externé zdroje ani nástroje na generovanie riešení (napr. UI) v rozpore s pravidlami predmetu.